

KBS – *EnergySafe* :

Sistema esperto multi-modello per la gestione intelligente dei carichi domestici

Gruppo di lavoro

- Lucia Meliota, 775374, l.meliota1@studenti.uniba.it

<https://github.com/MeliotaLucia/EnergySafe>

Anno Accademico 2025-2026

Introduzione

In questo progetto, il dominio di interesse è basato sul settore delle case intelligenti, ovvero le **smart home**, e della gestione intelligente del carico dell'energia utilizzata.

L'obiettivo del sistema è essere un assistente intelligente capace di suggerire azioni mediando fra la complessità dei dati energetici, fra cui carico totale, media dei consumi, elettrodomestici nello specifico, e l'utente finale, fornendo dei consigli proattivi basati sia su analisi probabilistiche che su regole logiche deterministiche.

Il motivo della scelta di questo settore è dovuto alla necessità di sistemi capaci di monitorare i consumi in tempo reale per prevenire situazioni di sovraccarico e anche ottimizzare l'utilizzo dell'energia basate, per esempio, sulle fasce orarie e sulla produzione locale come pannelli solari.

Il dataset utilizzato come base per il KBS è stato trovato su Kaggle, "*smart home dataset with weather information*", ed è stato scelto per la varietà di informazioni all'interno, come sensori per ogni elettrodomestico con il carico totale e indicazioni meteorologiche come temperatura e umidità. Il dataset contiene 32 colonne e 500.000 istanze con una divisione equa fra i casi di carico basso, carico medio e carico alto e le tipologie di fasce energetiche (F1, F2 e F3).

DISTRIBUZIONE DEI CONSUMI PER FASCIA ORARIA:			
	Carico Basso	Carico Medio	Carico Alto
Fascia Energetica			
F1	28.92%	34.01%	37.07%
F2	27.71%	34.37%	37.92%
F3	39.95%	32.22%	27.83%

Prima di lavorare sul dataset, è stata eseguita una fase di feature engineering, per focalizzarsi sulle colonne importanti presenti e crearne altre, come la tipologia della fascia energetica, le categorie di consumo e la media del consumo nelle ultime tre volte.

Sommario

Il Knowledge-Based System realizzato integra diversi moduli per coprire diversi ambiti dell'intelligenza artificiale:

- **Modulo di apprendimento supervisionato:** il KBS utilizza due modelli di classificazione supervisionata: albero decisionale e rete neurale MLP. Utilizza questi modelli per predire il livello del carico elettrico partendo dai dati dei sensori ottenuti dal dataset.
- **Modulo di apprendimento con incertezza:** il KBS si serve anche di un modello con incertezza, la rete bayesiana, per predire diversamente il livello del carico elettrico, ovvero eliminando il fattore della certezza ma parlando di probabilità del livello di carico, per far decidere poi all'utente finale stesso la scelta più consona.
- **Modulo di rappresentazione e ragionamento:** le predizioni dei moduli di apprendimento vengono combinate in una base di conoscenza strutturata basata su logica predicativa (Prolog). Il sistema applica le clausole di Horn per esporre consigli specifici come priorità di distacco e strategia di ottimizzazione.
- **Modulo di integrazione:** per unire i diversi moduli fra loro, è stato utilizzato un'interfaccia Python su Google Colab che garantisce coerenza tra il dato numerico, previsione del modello e risposta logica.

Elenco argomenti di interesse

- **Argomento 1 :** *Rappresentazione della conoscenza* (utilizzo delle clausole di Horn in linguaggio Prolog per definire le regole di dominio, gerarchie degli elettrodomestici e strategie di intervento)
- **Argomento 2 :** *Apprendimento supervisionato e con incertezza* (implementazione e confronto di modelli di classificazione quali Decision Tree, Belief Network e MLP per il ragionamento predittivo)
- **Argomento 3 :** *Sistemi basati sulla conoscenza e integrazione* (realizzazione del sistema integrato che combina ragionamento simbolico e sub-simbolico, nonché le reti neurali)

Argomento 1 : Rappresentazione della conoscenza

Sommario

Per la base di conoscenza è stata adottata una rappresentazione basata sulla logica predicativa attraverso l'uso delle clausole di Horn.

La scelta del linguaggio Prolog ha permesso di separare la logica del dominio, nonché le effettive regole della gestione energetica, dal controllo, ossia l'esecuzione del programma.

La conoscenza è strutturata in:

1. **Fatti:** definizioni statiche riguardanti gli elettrodomestici
 - a. La loro tipologia: critico (non è possibile il consiglio di spegnimento) o sacrificabile (è possibile il consiglio di spegnimento)
 - b. La loro priorità di distacco : da 1 (spegnere per primo) a 4 (spegnere per ultimo)
2. **Base di conoscenza dinamica:** asserzioni che variano nel tempo fornite dal modulo di Python, come lo stato di accensione dei carichi, la fascia oraria corrente e la predizione di rischio.
3. **Regole di ragionamento:** clausole definite che combinano i fatti alla situazione attuale per avere i consigli d'azione.

Strumenti utilizzati

- **SWI-Prolog:** motore inferenziale utilizzato per l'esecuzione della logica basata sulla risoluzione SLD.
- **PySwip:** libreria ponte utilizzata per l'integrazione tra l'ambiente di analisi dati (Python) e il motore logico, permettendo la comunicazione bidirezionale tra modelli di machine learning e basi di conoscenza.

Decisioni di Progetto

Nella configurazione sono state prese le seguenti decisioni:

1. È stata utilizzata la direttiva `:- dynamic stato/2` per consentire al sistema di aggiornare la memoria di lavoro in tempo reale, eliminando i fatti obsoleti tramite il meccanismo di retractall prima di ogni nuova inferenza.
2. Al fine di non sottoporsi al rumore che il dataset potesse avere riguardante i valori di potenza di ogni elettrodomestico, è stata definita **una soglia di potenza minima** per considerare un elettrodomestico acceso, ovvero al di sopra di 0.1 kW, evitando così i falsi positivi.
3. È stato implementato un **sistema di priorità numerica** per risolvere i conflitti in caso di carichi multipli. Il sistema sacrifica prima di dispositivi a bassa priorità per preservare quelli più importanti per l'utente.
4. Le regole sono state differenziate in base alla **fascia oraria**: in F1 (costosa) il ragionamento è orientato al risparmio energetico mentre il F3 (notturna e domenica) è orientato alla sicurezza tecnica al fine di evitare blackout.

Valutazione

L'efficacia della rappresentazione è stata valutata verificando la capacità del sistema di generare consigli coerenti anche con dati non completi.

Tipologia di regola	Condizione di Attivazione	Risultato Atteso	Risultato Ottenuto
Ottimizzazione	Produzione solare > 0.4 kW Produzione solare > Carico	OTTIMIZZAZIONE: La produzione di energia solare è alta al momento! Per sfruttarla è possibile accendere elettrodomestici come la lavastoviglie	OTTIMIZZAZIONE: La produzione di energia solare è alta al momento! Per sfruttarla è possibile accendere elettrodomestici come la lavastoviglie
Sicurezza	Carico ALTO in F3	SICUREZZA TECNICA: Anche se sei in fascia economica (F3), il carico totale è troppo alto e potrebbe verificarsi un blackout. Riduci l'uso di:	SICUREZZA TECNICA: Anche se sei in fascia economica (F3), il carico totale è troppo alto e potrebbe verificarsi un blackout. Riduci l'uso di: ELETTRODOMESTICO ACCESO
Prudenza	Carico ALTO e sensori non accesi	ATTENZIONE: Previsione di carico elevato. Anche se i grandi elettrodomestici sono spenti, evita di accenderne di nuovi!	ATTENZIONE: Previsione di carico elevato. Anche se i grandi elettrodomestici sono spenti, evita di accenderne di nuovi!

Argomento 2 : Apprendimento supervisionato e con incertezza

Sommario

Per l'apprendimento automatico volta a prevedere il livello di carico energetico, sono stati implementati e integrati tre modelli eterogenei:

- Albero decisionale
- Rete neurale
- Rete bayesiana

Il problema è stato modellato come un compito di classificazione supervisionata in tre classi: basso, medio e alto.

Strumenti utilizzati

- **Scikit-learn**: per l'implementazione dell'Albero Decisionale e del Multi-Layer Perceptron.
- **Pandas & NumPy**: per il preprocessing dei dati e la manipolazione dei dataset.
- **pgmpy**: utilizzata per l'implementazione della Rete Bayesiana e l'inferenza probabilistica.

Albero Decisionale

Rappresentazione:

Il modello utilizza una struttura gerarchica di nodi per partizionare in base a soglie ottimali delle feature, principalmente il valore use (carico totale).

Comportamento:

Si è mostrato il modello più deterministico e coerente rispetto ai valori di potenza assoluti. È particolarmente efficace nel definire confini netti per la sicurezza, rendendo il ragionamento facilmente interpretabile.

Valutazione:

Il modello è estremamente affidabile nei carichi estremi, basso e alto. Il carico medio risulta essere la classe con le performance peggiori.

PRESTAZIONI DEL MODELLO SUL TEST SET:				
	Precisione	Recall	F1-Score	Numero di righe (Esempi)
Basso	95.69%	92.62%	94.13%	33823
Medio	87.58%	88.63%	88.10%	33600
Alto	92.14%	94.01%	93.07%	33359
Accuratezza Totale del Modello: 91.75%				

La scelta dei parametri di addestramento dell'albero ha richiesto una particolare attenzione alla gestione della profondità massima del modello. Avendo a disposizione un dataset di grandi dimensioni (circa 500.000 istanze), l'assenza di un vincolo sulla crescita dei nodi avrebbe portato il classificatore a generare una struttura eccessivamente complessa e ramificata, memorizzando il rumore statistico dei dati anziché estrarre regole generali (fenomeno di *overfitting*). Pertanto, a seguito di un processo di ottimizzazione empirica, si è deciso di impostare l'iperparametro `max_depth = 5`. Tale vincolo si è dimostrato il miglior compromesso ingegneristico, garantendo un'elevata accuratezza predittiva (91.75%).

Rete Neurale

Rappresentazione:

Il modello sub-simbolico è composto da strati di neuroni artificiali che apprendono pattern complessi non lineari attraverso l'algoritmo di backpropagation.

Inizialmente si è modellata la rete neurale con due layer, la prima contenente 100 neuroni e la seconda 50 neuroni. Una volta addestrato si è rivelata con una accuratezza inferiore rispetto all'albero decisionale in tutte le tipologie di carico.

Al fine di migliorare l'accuratezza dell'intero sistema è stata aumentata la rete neurale a tre layer, formati da rispettivamente 128 neuroni, 64 neuroni e 32 neuroni, abbassando il massimo di iterate a 200 per terminare prima il ragionamento. L'aumento della rete neurale è direttamente proporzionale al tempo di esecuzione che è raddoppiata, arrivando ad 1h e 06 min, ma inversamente proporzionale all'accuratezza, risultando inferiore alla rete neurale con due layer da 100 neuroni e 50 neuroni.

Come ultima prova si è provato a ridurre la rete neurale, mantenendo due layer, ma portando i neuroni a 64 per il primo layer e 32 per il secondo. I risultati emersi indicano una netta discesa rispetto agli ultimi due tentativi.

Pertanto, la rete neurale ottimale è formata da due layer, uno da 100 neuroni e uno da 50 neuroni. Per ottimizzare il processo di addestramento su un volume di dati così consistente, è stata anche introdotta la clausola di `early_stopping = true`. Questo iperparametro monitora la loss function sul set di validazione interna e arresta automaticamente le iterazioni non appena il miglioramento della funzione obiettivo scende sotto una tolleranza predefinita per dieci iterate consecutive. In fase finale si è deciso di togliere tale parametro perché, nonostante avesse ridotto notevolmente il tempo di lavorazione, ha ridotto anche l'accuratezza finale.

Comportamento:

Nonostante un'elevata accuratezza teorica, i test hanno evidenziato una tendenza alla generalizzazione verso la classe media. A differenza dell'albero decisionale, la rete neurale non segue soglie rigide ma tenta di identificare il carico totale da altri fattori non per forza rilevanti, portando a sottostimare picchi improvvisi.

Valutazione:

Il modello, avendo appreso pattern molto complessi, tende a indicare sempre carico MEDIO se la combinazione degli elettrodomestici accesi non corrisponde esattamente a un profilo ALTO noto. Questo conferma che l'accuratezza statistica non sempre coincide con l'affidabilità in casi critici.

Importante, però, è la deviazione standard nettamente migliore rispetto all'albero decisionale. Pertanto, è possibile dire che è molto più stabile dell'albero decisionale.

RISULTATI RETE NEURALE (MLP):
Accuratezza: 91.64%

	Precisione	Recall	F1-Score	Esempi
Basso	95.39%	92.86%	94.11%	33823
Medio	87.63%	88.22%	87.92%	33600
Alto	91.99%	93.85%	92.91%	33359

Avvio Cross-Validation veloce sulla Rete Neurale (10 fold su 100.000 righe)...

CONFRONTO FINALE:
MLP Accuratezza Media: 91.45%
MLP Deviazione Standard: 0.25%

Rete Bayesiana

Rappresentazione:

Questo modello affronta l'incertezza attraverso la probabilità condizionata. Calcola la probabilità che il carico sia ALTO data la combinazione di elettrodomestici accesi e il carico totale.

Al modello si sarebbe voluto aggiungere anche la presenza umana per condizionare i consumi, ma non avendo alcun sensore che possa definire il movimento o la presenza di qualcuno, si è deciso di non includere una variabile predefinita per evitare di introdurre bias deterministici. Provato ad inserire la variabile, si è notato come il sistema sia diventato rigido; pertanto, si è preferito lasciare che la rete apprendesse le correlazioni tra variabili ambientali e carico energetico.

Comportamento:

Il modello è ottimo per la gestione tra variabili. Ad esempio, se il forno e il microonde sono accesi, la probabilità di carico ALTO sale drasticamente, permettendo un ragionamento probabilistico che integra bene i dati dei sensori incompleti.

Valutazione:

La rete bayesiana è stata valutata sulla sua capacità di gestire l'incertezza legata alla combinazione degli elettrodomestici.

Questa è meno influenzata dai valori anomali di "use" rispetto all'albero, poiché prende più in considerazione la configurazione dei sensori.

(è presente una query per verificare il funzionamento del modello e l'accuratezza sottostante.)

Qual è la probabilità del carico se è mattina nella fascia 1 e la media dei consumi è alto?

Stato Carico	Probabilità
--------------	-------------

Basso	2.16%
Medio	8.22%
Alto	89.62%

Calcolo delle predizioni in corso...

100%  518/518 [00:16<00:00, 188.44it/s]

Accuratezza Rete Bayesiana: 91.02%

Valutazione

Modello	Accuracy
<i>Albero decisionale</i>	91.75%
<i>Rete neurale</i>	91.64%
<i>Rete bayesiana</i>	91.02%

Argomento 3 : Sistemi basati sulla conoscenza e integrazione

Sommario

In questa fase di ricerca, l'obiettivo è stato quello di integrare i singoli modelli di machine learning per arrivare alla creazione di un **sistema basato sulla conoscenza** scritto in Prolog.

Il modello finale prende le decisioni definite dai tre modelli e calcola la predizione che verrà visualizzata all'utente finale, mantenendo però tutti i classificatori diversificati in caso si voglia avere una spiegazione del motivo per cui il sistema finale ha deciso una determinata azione.

Strumenti utilizzati

- **SWI-Prolog**: Motore di inferenza utilizzato per definire le regole logiche, i vincoli di sicurezza e le gerarchie di carico.
- **PySwip**: Libreria ponte che permette l'interazione bidirezionale tra l'ambiente Python (dove risiedono i modelli IA) e il modulo Prolog.
- **Python (Pandas/NumPy)**: Utilizzati per la pre-elaborazione dei dati dei sensori in tempo reale prima dell'invio alla KB.

Decisioni di Progetto

Il sistema è stato guidato da due necessità critiche emerse durante i test:

1. **Strategia del "voto conservativo"**: si è deciso di implementare un meccanismo di voto pesato. Questo è dovuto alla natura della rete neurale: questa predilige la tipologia di carico MEDIA nonostante il carico totale sia elevato. Pertanto, se l'albero decisionale o/e la rete bayesiana rilevano una classe di tipo ALTA, il sistema prioritizza questa segnalazione rispetto alla rete neurale.
2. **Mapping semantico e normalizzazione**: per colmare il divario fra l'output numerico e la logica simbolica di Prolog, è stato necessario aggiungere un layer di traduzione affinché non ci fossero errori di comunicazione.

Valutazione

L'efficacia dell'integrazione è stata validata attraverso scenari critici in cui si hanno predizioni discordanti, che potrebbero confondere l'utente finale.

Un esempio di questi scenari critici è il seguente:

```

ANALISI SCENARIO: 13602
Carico Misurata: 2.0103 kW
Il modello Albero Decisionale predice che il carico sia ALTO
-> ECONOMIA: Fascia costosa e carico alto. Si consiglia di sospendere: LAVASTOVIGLIE
-> INFO: Il frigo è in funzione e contribuisce al carico, ma non verrà disattivato.
-----
Il modello Rete Neurale (MLP) predice che il carico sia MEDIO
-> ATTENZIONE: Storicamente in questa fascia il rischio di picchi è alto. Evita di accendere nuovi carichi ora!
-----
Per il modello Rete Bayesiana, la probabilità che il carico sia ALTO è del 91.00%
-> ECONOMIA: Fascia costosa e carico alto. Si consiglia di sospendere: LAVASTOVIGLIE
-> INFO: Il frigo è in funzione e contribuisce al carico, ma non verrà disattivato.
-----

Esito del voto: Voto Conservativo: Sicurezza garantita da Albero/Bayes

=====
>>> ANALISI INTEGRATA KB FINALE (SISTEMA ESPERTO) <<<
Decisione tipologia del carico: ALTO

Consigli del sistema esperto: (Fascia F1):
INFO: Il frigo è in funzione e contribuisce al carico, ma non verrà disattivato.
ECONOMIA: Fascia costosa e carico alto. Si consiglia di sospendere: LAVASTOVIGLIE
=====

```

Dall'analisi delle prestazioni, si osserva che l'accuratezza del sistema integrato converge con quella ottenuta dall'albero decisionale: il sistema di integrazione è stato progettato come un filtro, attraverso il meccanismo di voto, il sistema ignora il bias della rete neurale quando le predizioni di questa contrastano quelle degli altri due modelli. Di conseguenza, l'accuratezza finale del sistema si attesta sul valore del modello più performante.

```

=====
ACCURACY SISTEMA INTEGRATO: 91.75%
=====

REPORT DI CLASSIFICAZIONE:

```

	precision	recall	f1-score	support
Basso	0.96	0.93	0.94	33823
Medio	0.88	0.89	0.88	33600
Alto	0.92	0.94	0.93	33359

Conclusioni

Questo progetto ha dimostrato l'efficacia di un'architettura basata su modelli eterogenei per la gestione energetica domestica.

L'integrazione tra modelli di Machine Learning e Sistemi Basati sulla Conoscenza ha permesso di superare i limiti di entrambi gli approcci: se da un lato l'IA ha garantito la capacità di apprendere dai dati storici e fare predizioni, dall'altro la logica Prolog ha fornito i motivi e sicurezza indispensabile in contesti domestici.

L'integrazione ha permesso di avere un sistema unico anche nel caso in cui i modelli fornivano predizioni discordanti e, a differenza di modelli AI basati solo sulla statistica, il KBS ha dimostrato di sapere distinguere un carico alto in Fascia F1, chiedendo all'utente di diminuire il carico, e un carico alto in Fascia F3, che attiva la regola della sicurezza tecnica.

Infine, il sistema produce consigli leggibili e spiegabili, per esempio consigliare lo spegnimento dell'elettrodomestico con priorità inferiore acceso, aumentando la trasparenza e facilità di lettura del sistema stesso.

Riferimenti Bibliografici

- **Artificial Intelligence: Foundations of Computational Agents** – per la parte teorica
- **Prolog Programming for Artificial Intelligence** – per la programmazione in Prolog