

KBS – *EnergySafe* :

Sistema esperto multi-modello per la gestione intelligente dei carichi domestici

Gruppo di lavoro

- Lucia Meliota, 775374, l.meliota1@studenti.uniba.it

<https://github.com/MeliotaLucia/EnergySafe>

Anno Accademico 2025-2026

Introduzione

In questo progetto, il dominio di interesse è basato sul settore delle case intelligenti, ovvero le **smart home**, e della gestione intelligente del carico dell'energia utilizzata.

L'obiettivo del sistema è essere un assistente intelligente capace di suggerire azioni mediando fra la complessità dei dati energetici, fra cui carico totale, media dei consumi, elettrodomestici nello specifico, e l'utente finale, fornendo dei consigli proattivi basati sia su analisi probabilistiche che su regole logiche deterministiche.

Il motivo della scelta di questo settore è dovuto alla necessità di sistemi capaci di monitorare i consumi in tempo reale per prevenire situazioni di sovraccarico e anche ottimizzare l'utilizzo dell'energia basate, per esempio, sulle fasce orarie e sulla produzione locale come pannelli solari.

Il dataset utilizzato come base per il KBS è stato trovato su Kaggle, "*smart home dataset with weather information*", ed è stato scelto per la varietà di informazioni all'interno, come sensori per ogni elettrodomestico con il carico totale e indicazioni meteorologiche come temperatura e umidità. Il dataset contiene 32 colonne e 500.000 istanze con una divisione equa fra i casi di carico basso, carico medio e carico alto e le tipologie di fasce energetiche (F1, F2 e F3).

DISTRIBUZIONE DEI CONSUMI PER FASCIA ORARIA:			
	Carico Basso	Carico Medio	Carico Alto
Fascia Energetica			
F1	28.92%	34.01%	37.07%
F2	27.71%	34.37%	37.92%
F3	39.95%	32.22%	27.83%

Prima di lavorare sul dataset, è stata eseguita una fase di feature engineering, per focalizzarsi sulle colonne importanti presenti e crearne altre, come la tipologia della fascia energetica, le categorie di consumo e la media del consumo nelle ultime tre volte.

Sommario

Elenco argomenti di interesse	3
Argomento 1 : Rappresentazione della conoscenza.....	4
Sommario	4
Strumenti utilizzati	4
Decisioni di Progetto	4
Valutazione	5
Argomento 2 : Apprendimento supervisionato e con incertezza	6
Sommario	6
Strumenti utilizzati	6
Albero Decisionale	6
Rete Neurale	7
Rete Bayesiana.....	9
Tabella complessiva delle valutazioni finali	10
Argomento 3 : Sistemi basati sulla conoscenza e integrazione	11
Sommario	11
Strumenti utilizzati	11
Decisioni di Progetto	11
Valutazione	12
Conclusioni.....	13
Riferimenti Bibliografici.....	13

Elenco argomenti di interesse

Il Knowledge-Based System realizzato integra diversi moduli per coprire diversi ambiti dell'intelligenza artificiale:

- **Modulo di apprendimento supervisionato:** il KBS utilizza due modelli di classificazione supervisionata: albero decisionale e rete neurale MLP. Utilizza questi modelli per predire il livello del carico elettrico partendo dai dati dei sensori ottenuti dal dataset.
- **Modulo di apprendimento con incertezza:** il KBS si serve anche di un modello con incertezza, la rete bayesiana, per predire diversamente il livello del carico elettrico, ovvero eliminando il fattore della certezza ma parlando di probabilità del livello di carico, per far decidere poi all'utente finale stesso la scelta più consona.
- **Modulo di rappresentazione e ragionamento:** le predizioni dei moduli di apprendimento vengono combinate in una base di conoscenza strutturata basata su logica predicativa (Prolog). Il sistema applica le clausole di Horn per esporre consigli specifici come priorità di distacco e strategia di ottimizzazione.
- **Modulo di integrazione:** per unire i diversi moduli fra loro, è stato utilizzato un'interfaccia Python su Google Colab che garantisce coerenza tra il dato numerico, previsione del modello e risposta logica.

Al fine di schematizzare formalmente i moduli appena descritti, le tematiche di progettuali di tali moduli vengono ricondotti nei tre argomenti principali:

- **Argomento 1 :** *Rappresentazione della conoscenza* (utilizzo delle clausole di Horn in linguaggio Prolog per definire le regole di dominio, gerarchie degli elettrodomestici e strategie di intervento)
- **Argomento 2 :** *Apprendimento supervisionato e con incertezza* (implementazione e confronto di modelli di classificazione quali Decision Tree, Belief Network e MLP per il ragionamento predittivo)
- **Argomento 3 :** *Sistemi basati sulla conoscenza e integrazione* (realizzazione del sistema integrato che combina ragionamento simbolico e sub-simbolico, nonché le reti neurali)

Argomento 1 : Rappresentazione della conoscenza

Sommario

Per la base di conoscenza è stata adottata una rappresentazione basata sulla logica predicativa attraverso l'uso delle clausole di Horn in linguaggio Prolog.

La scelta del linguaggio Prolog ha permesso di separare la logica del dominio, nonché le effettive regole della gestione energetica, dal controllo, ossia l'esecuzione del programma. Il motore inferenziale è stato sviluppato in modo tale da superare il semplice patter matching, tipico delle interrogazioni a un database relazionale, per implementare un motore inferenziale dinamico.

La conoscenza è strutturata in:

1. **Fatti statici:** definizioni statiche e strutturali riguardanti gli elettrodomestici:
 - a. La loro tipologia: critico (non è possibile il consiglio di spegnimento) o sacrificabile (è possibile il consiglio di spegnimento).
 - b. La loro priorità di distacco : da 1 (spegnere per primo) a 4 (spegnere per ultimo)
2. **Fatti dinamica:** asserzioni che variano nel tempo fornite dal modulo di Python tramite la direttiva `dynamic`, che definiscono lo stato dei sensori, la fascia oraria e le previsioni di rischio.
3. **Regole di ragionamento:** costrutti logici complessi (come metaprogrammazione e ricorsione) che analizzano lo stato della rete domestica per generare stringhe di distacco sequenziale personalizzate.

Strumenti utilizzati

- **SWI-Prolog:** motore inferenziale utilizzato per l'esecuzione della logica basata sulla risoluzione SLD.
- **PySwip:** libreria ponte utilizzata per l'integrazione tra l'ambiente di analisi dati (Python) e il motore logico, permettendo la comunicazione bidirezionale tra modelli di machine learning e basi di conoscenza.

Decisioni di Progetto

Per garantire un livello di complessità adeguato, sono state prese le seguenti decisioni implementative:

- **Filtraggio del rumore:** per evitare l'attivazione di falsi positivi causati da micro-assorbimenti, lo stato "acceso" di un dispositivo viene asserito solo se l'assorbimento supera la soglia di 0.1 kW.
- **Metapredicati per l'analisi del contesto:** è stato utilizzato il predicato `findall/3` per raccogliere dinamicamente tutti i carichi attivi e sacrificabili in un dato istante. Questo permette al sistema di non basarsi su regole *hard-coded* per ogni singola combinazione di dispositivi.
- **Ordinamento Logico:** attraverso il predicato `keysort/2`, il sistema ordina autonomamente la lista degli elettrodomestici in base al loro indice di priorità, garantendo che le azioni suggerite minimizzino il disagio per l'utente.

- **Ricorsione per la generazione del piano:** un algoritmo ricorsivo (estrai_elettrodomestici/2) scorre la lista ordinata, isolando i nomi dei dispositivi e costruendo il piano d'azione sequenziale.
- **Differenziazione Semantica per Fasce:** le regole inferenziali finali fondono il piano generato dinamicamente con il contesto economico: in fascia F1 il distacco è motivato dal risparmio economico, mentre in fascia F3 (notturna/festiva) il distacco viene suggerito esclusivamente per ragioni di sicurezza tecnica al fine di prevenire un blackout da sovraccarico.

Valutazione

L'efficacia della rappresentazione è stata valutata verificando la capacità del sistema di generare consigli coerenti anche con dati non completi.

Tipologia di regola	Condizione di Attivazione	Risultato Atteso	Risultato Ottenuto
Ottimizzazione	Produzione solare > 0.4 kW Produzione solare > Carico	OTTIMIZZAZIONE: La produzione di energia solare è alta al momento! Per sfruttarla è possibile accendere elettrodomestici come la lavastoviglie	OTTIMIZZAZIONE: La produzione di energia solare è alta al momento! Per sfruttarla è possibile accendere elettrodomestici come la lavastoviglie
Sicurezza	Carico ALTO in F3	SICUREZZA TECNICA: Anche se sei in fascia economica (F3), il carico totale è troppo alto e potrebbe verificarsi un blackout. Riduci l'uso di:	SICUREZZA TECNICA: Anche se sei in fascia economica (F3), il carico totale è troppo alto e potrebbe verificarsi un blackout. Riduci l'uso di: ELETTRODOMESTICO ACCESO
Prudenza	Carico ALTO e sensori non accesi	ATTENZIONE: Previsione di carico elevato. Anche se i grandi elettrodomestici sono spenti, evita di accenderne di nuovi!	ATTENZIONE: Previsione di carico elevato. Anche se i grandi elettrodomestici sono spenti, evita di accenderne di nuovi!

Argomento 2 : Apprendimento supervisionato e con incertezza

Sommario

Per l'apprendimento automatico volta a prevedere il livello di carico energetico, sono stati implementati e integrati tre modelli eterogenei:

- Albero decisionale
- Rete neurale MLP
- Rete bayesiana

Il problema è stato modellato come un compito di classificazione supervisionata in tre classi: basso, medio e alto.

Il passaggio fondamentale di questa implementazione è stato il superamento della validazione su singola run (train/test split), adottando per tutti i modelli una cross-validation, precisamente k-fold con k=5, e l'ottimizzazione algoritmica degli iperparametri, al fine di garantire la validità statistica e prevenire l'overfitting.

Strumenti utilizzati

- **Scikit-learn**: per l'implementazione dell'Albero Decisionale e del Multi-Layer Perceptron.
- **Pandas & NumPy**: per il preprocessing dei dati e la manipolazione dei dataset.
- **pgmpy**: utilizzata per l'implementazione della Rete Bayesiana e l'inferenza probabilistica.

Albero Decisionale

Rappresentazione e Comportamento:

Il modello utilizza una struttura gerarchica di nodi per partizionare in base a soglie ottimali delle feature, principalmente il valore use (carico totale) e la fascia oraria.

Si è mostrato il modello più deterministico e coerente rispetto ai valori di potenza assoluti. È particolarmente efficace nel definire confini netti per la sicurezza, rendendo il ragionamento facilmente interpretabile.

Ottimizzazione e Valutazione:

Il modello è estremamente affidabile nei carichi estremi, basso e alto. Il carico medio risulta essere la classe con le performance peggiori.

RISULTATI OTTIMIZZAZIONE ALBERO DECISIONALE:

Migliori iperparametri trovati: {'criterion': 'gini', 'max_depth': 3, 'min_samples_split': 2}
Accuratezza Media in CV (K-Fold=5): 91.75%
Deviazione Standard in CV: 0.05%

PRESTAZIONI DEL MODELLO OTTIMIZZATO SUL TEST SET FINALE:

	Precisione	Recall	F1-Score	Numero di righe (Esempi)
Basso	95.68%	92.69%	94.16%	33823
Medio	87.63%	88.62%	88.12%	33600
Alto	92.14%	94.01%	93.07%	33359

Accuratezza Totale sul Test Set: 91.77%

Per evitare il fenomeno dell'overfitting, la scelta degli iperparametri non è stata condotta empiricamente, ma formalizzata tramite GridSearchCV integrata con una 5-Fold Cross-Validation. L'ottimizzatore ha esplorato 30 combinazioni diverse, decretando che la configurazione ottimale richiede una profondità massima ridotta (max_depth=3) e il criterio di impurità di Gini (criterion='gini'). Tale vincolo si è dimostrato il miglior compromesso ingegneristico, garantendo un'elevata accuratezza predittiva (91.75%).

La sua deviazione standard (0.05%) indica un'altissima stabilità del modello.

Rete Neurale

Rappresentazione e Comportamento:

Il modello sub-simbolico è composto da strati di neuroni artificiali che apprendono pattern complessi non lineari attraverso l'algoritmo di backpropagation.

Nonostante un'elevata accuratezza teorica, i test hanno evidenziato una tendenza alla generalizzazione verso la classe media. A differenza dell'albero decisionale, la rete neurale non segue soglie rigide ma tenta di identificare il carico totale da altri fattori non per forza rilevanti, portando a sottostimare picchi improvvisi. Dunque, questo comportamento (bias verso la classe centrale) non è un errore di addestramento, ma una caratteristica strutturale della rete

Ottimizzazione e Valutazione:

Inizialmente si è cercato di avere un'ottimizzazione attraverso una serie di test empirici, descritti di seguito:

Inizialmente si è modellata la rete neurale con due layer, la prima contenente 100 neuroni e la seconda 50 neuroni. Una volta addestrato si è rivelata con una accuratezza inferiore rispetto all'albero decisionale in tutte le tipologie di carico.

Al fine di migliorare l'accuratezza dell'intero sistema è stata aumentata la rete neurale a tre layer, formati da rispettivamente 128 neuroni, 64 neuroni e 32 neuroni, abbassando il massimo di iterate a 200 per terminare prima il ragionamento. L'aumento della rete neurale è direttamente proporzionale al tempo di esecuzione che è raddoppiata, arrivando ad 1h e 06 min, ma inversamente proporzionale all'accuratezza, risultando inferiore alla rete neurale con due layer da 100 neuroni e 50 neuroni.

Come ultima prova si è provato a ridurre la rete neurale, mantenendo due layer, ma portando i neuroni a 64 per il primo layer e 32 per il secondo. I risultati emersi indicano una netta discesa rispetto agli ultimi due tentativi.

Pertanto, la rete neurale ottimale è formata da due layer, uno da 100 neuroni e uno da 50 neuroni. Per ottimizzare il processo di addestramento su un volume di dati così consistente, è stata anche introdotta la clausola di `early_stopping = true`. Questo iperparametro monitora la loss function sul set di validazione interna e arresta automaticamente le iterazioni non appena il miglioramento della funzione obiettivo scende sotto una tolleranza predefinita per dieci iterate consecutive. In fase finale si è deciso di togliere tale parametro perché, nonostante avesse ridotto notevolmente il tempo di lavorazione, ha ridotto anche l'accuratezza finale.

In seguito, è stato deciso di utilizzare la GridSearchCV al fine di avere una scelta di iperparametri definiti statisticamente.

A causa dell'elevato costo computazionale, l'ottimizzazione è stata condotta su un campione stratificato di 100.000 istanze, garantendo la conservazione della distribuzione statistica delle classi. La GridSearchCV (5-Fold CV) ha dimostrato che aumentare i neuroni non migliora necessariamente le performance: l'architettura vincente è risultata quella più "leggera" con due layer da 64 e 32 neuroni, rispetto a due layer da 100 e 50 neuroni, associata alla funzione di attivazione tanh e al parametro `early_stopping=True`.

Il modello, avendo appreso pattern molto complessi, tende a indicare sempre carico MEDIO se la combinazione degli elettrodomestici accesi non corrisponde esattamente a un profilo ALTO noto. Questo conferma che l'accuratezza statistica non sempre coincide con l'affidabilità in casi critici.

RISULTATI OTTIMIZZAZIONE RETE NEURALE:

Migliori iperparametri trovati: {'activation': 'tanh', 'early_stopping': True, 'hidden_layer_sizes': (64, 32)}

Accuratezza Media in CV (K-Fold=3): 91.37%

Deviazione Standard in CV: 0.19%

PRESTAZIONI DELLA RETE NEURALE OTTIMIZZATA SUL TEST SET:

	Precisione	Recall	F1-Score	Esempi
Basso	94.88%	92.94%	93.90%	6715
Medio	87.74%	86.63%	87.18%	6666
Alto	91.08%	94.12%	92.58%	6619

Accuratezza Totale sul Test Set: 91.23%

Rete Bayesiana

Rappresentazione e Comportamento:

Questo modello affronta l'incertezza attraverso la probabilità condizionata. Esso calcola la probabilità che il carico sia ALTO data la combinazione di elettrodomestici accesi e il carico totale. Richiedendo feature discrete, le variabili continue originali (come temperatura e umidità) sono state preprocessate e raggruppate in categorie semantiche tramite funzioni di partizionamento (qcut e cut).

Al modello si sarebbe voluto aggiungere anche la presenza umana per condizionare i consumi, ma non avendo alcun sensore che possa definire il movimento o la presenza di qualcuno, si è deciso di non includere una variabile predefinita per evitare di introdurre bias deterministici. Provato ad inserire la variabile, si è notato come il sistema sia diventato rigido; pertanto, si è preferito lasciare che la rete apprendesse le correlazioni tra variabili ambientali e carico energetico.

La rete modella in modo eccellente le relazioni di dipendenza causa-effetto tra variabili. Ad esempio, se il forno e il microonde sono accesi, la probabilità di carico ALTO sale drasticamente, permettendo un ragionamento probabilistico che integra bene i dati dei sensori incompleti.

Ottimizzazione e Valutazione:

Per garantire una validazione scientifica ed evitare il fenomeno del *data leakage* (addestramento e test sui medesimi dati), è stato implementato un ciclo manuale di 5-Fold Cross-Validation su un campione rappresentativo di 100.000 istanze, per coerenza con la rete neurale.

Ad ogni iterazione, il modello è stato addestrato esclusivamente sul fold di training (usando la Maximum Likelihood) e valutato sul fold di test.

La rete bayesiana è meno influenzata dai valori anomali di "use" rispetto all'albero, poiché prende più in considerazione la configurazione dei sensori.

(è presente una query per verificare il funzionamento del modello e l'accuratezza sottostante.)

Avvio Cross-Validation (5-Fold) per la Rete Bayesiana...

100%  471/471 [00:04<00:00, 117.30it/s]

Completato Fold 1/5: Accuratezza 90.70%

100%  475/475 [00:03<00:00, 137.73it/s]

Completato Fold 2/5: Accuratezza 90.90%

100%  480/480 [00:03<00:00, 142.09it/s]

Completato Fold 3/5: Accuratezza 91.20%

100%  487/487 [00:03<00:00, 139.43it/s]

Completato Fold 4/5: Accuratezza 90.83%

100%  480/480 [00:03<00:00, 140.46it/s]

Completato Fold 5/5: Accuratezza 91.31%

RISULTATI CROSS-VALIDATION RETE BAYESIANA:

Accuratezza Media in CV (K-Fold=5): 90.98%

Deviazione Standard in CV: 0.23%

Tabella complessiva delle valutazioni finali

Modello	Accuracy
<i>Albero decisionale</i>	91.75%
<i>Rete neurale</i>	91.23%
<i>Rete bayesiana</i>	90.98%

Argomento 3 : Sistemi basati sulla conoscenza e integrazione

Sommario

In questa fase di ricerca, l'obiettivo è stato quello di integrare i singoli modelli di machine learning per arrivare alla creazione di un **sistema basato sulla conoscenza** scritto in Prolog.

Il modello finale prende le decisioni definite dai tre modelli e calcola la predizione che verrà visualizzata all'utente finale, mantenendo però tutti i classificatori diversificati in caso si voglia avere una spiegazione del motivo per cui il sistema finale ha deciso una determinata azione.

Strumenti utilizzati

- **SWI-Prolog**: Motore di inferenza utilizzato per definire le regole logiche, i vincoli di sicurezza e le gerarchie di carico.
- **PySwip**: Libreria ponte che permette l'interazione bidirezionale tra l'ambiente Python (dove risiedono i modelli IA) e il modulo Prolog.
- **Python (Pandas/NumPy)**: Utilizzati per la pre-elaborazione dei dati dei sensori in tempo reale prima dell'invio alla KB.

Decisioni di Progetto

Il sistema integrato è stato riprogettato per risolvere le criticità emerse durante i test iniziali, portando alle seguenti decisioni architetturali:

1. **Dal Voto Conservativo al Voto di Maggioranza (Majority Voting)**: inizialmente si era adottato un "voto conservativo" forzato per compensare le lacune della Rete Neurale. Grazie alla rigorosa ottimizzazione degli iperparametri (che ha stabilizzato l'MLP), il sistema ora utilizza un vero voto di maggioranza democratico: la decisione finale corrisponde alla classe prevista da almeno 2 modelli su 3. È stato inoltre implementato un *fallback* di sicurezza: nell'improbabile caso di una parità totale (un voto per ogni classe), il sistema opta automaticamente per il carico "Alto", garantendo la protezione della rete domestica.
2. **Compensazione dei Bias**: l'integrazione multi-modello si è rivelata cruciale per correggere i fisiologici limiti dei singoli algoritmi. Come emerso dai test, la Rete Neurale tende talvolta a sottostimare i picchi improvvisi classificandoli come "Medio". Tuttavia, se l'Albero Decisionale e la Rete Bayesiana riconoscono l'anomalia votando "Alto", il sistema integrato neutralizza il bias della MLP, dimostrando la superiorità di un approccio *ensemble* rispetto al singolo classificatore.
3. **Delega del Ragionamento Simbolico a Prolog**: A differenza delle versioni preliminari in cui Python formattava attivamente l'output, l'architettura finale centralizza tutta l'intelligenza nella KB. La funzione Python `aggiorna_prolog_senza_errori` si limita a tradurre i dati grezzi in fatti logici. È il motore inferenziale di Prolog che si fa carico di ordinare le liste, valutare le fasce orarie e restituire le stringhe testuali già complete del piano di distacco, trasformando Python in un semplice "interprete" delle conseguenze logiche.

Valutazione

L'efficacia dell'integrazione è stata validata attraverso scenari critici in cui si hanno previsioni discordanti, che potrebbero confondere l'utente finale.

Di seguito si riportano il log di due esecuzioni:

- *Scenario 13602*, che dimostra come il sistema risolva il conflitto tramite il voto di maggioranza e come il motore Prolog assembli dinamicamente la sequenza di spegnimento in base alla priorità degli elettrodomestici attivi:

```
ANALISI SCENARIO: 13602
Carico Misurato: 2.0103 kW
Il modello Albero Decisionale predice che il carico sia ALTO
-> ECONOMIA: Fascia costosa e carico alto. Si consiglia la seguente sequenza di distacco: lavastoviglie
-> INFO: Il frigo e' in funzione e contribuisce al carico, ma essendo un dispositivo critico non verra' disattivato.
-----
Il modello Rete Neurale (MLP) predice che il carico sia MEDIO
-> Sistema in equilibrio. Nessun distacco o avviso necessario.
-----
Per il modello Rete Bayesiana, la probabilità che il carico sia ALTO è del 92.00%
-> ECONOMIA: Fascia costosa e carico alto. Si consiglia la seguente sequenza di distacco: lavastoviglie
-> INFO: Il frigo e' in funzione e contribuisce al carico, ma essendo un dispositivo critico non verra' disattivato.
-----

Esito del voto: Voto di Maggioranza democratica (2 su 3 modelli concordano su ALTO)

=====
>>> ANALISI INTEGRATA KB FINALE (SISTEMA ESPERTO) <<<
Decisione tipologia del carico (Voto Maggioranza): ALTO

Consigli del sistema esperto (Fascia F1):
[*] ECONOMIA: Fascia costosa e carico alto. Si consiglia la seguente sequenza di distacco: lavastoviglie
[*] INFO: Il frigo e' in funzione e contribuisce al carico, ma essendo un dispositivo critico non verra' disattivato.
=====
```

- *Scenario 634*, che dimostra come il sistema fornisca la sequenza di elettrodomestici di cui è consigliato lo spegnimento, in maniera dinamica, partendo dall'elettrodomestico che consuma maggiormente e più sacrificabile:

```
Seleziona scenario (da 1 a 503.909) - 0 per uscire: 634

ANALISI SCENARIO: 634
Carico Misurato: 1.9180 kW
Il modello Albero Decisionale predice che il carico sia ALTO
-> SICUREZZA TECNICA: Anche se sei in fascia F3, il carico e' troppo alto e rischi un blackout. Riduci subito l'uso di: forno2 poi forno1
-----
Il modello Rete Neurale (MLP) predice che il carico sia ALTO
-> SICUREZZA TECNICA: Anche se sei in fascia F3, il carico e' troppo alto e rischi un blackout. Riduci subito l'uso di: forno2 poi forno1
-----
Per il modello Rete Bayesiana, la probabilità che il carico sia ALTO è del 94.07%
-> SICUREZZA TECNICA: Anche se sei in fascia F3, il carico e' troppo alto e rischi un blackout. Riduci subito l'uso di: forno2 poi forno1
-----

Esito del voto: Voto di Maggioranza democratica (3 su 3 modelli concordano su ALTO)

=====
>>> ANALISI INTEGRATA KB FINALE (SISTEMA ESPERTO) <<<
Decisione tipologia del carico (Voto Maggioranza): ALTO

Consigli del sistema esperto (Fascia F3):
[*] SICUREZZA TECNICA: Anche se sei in fascia F3, il carico e' troppo alto e rischi un blackout. Riduci subito l'uso di: forno2 poi forno1
=====
```

Dall'analisi delle prestazioni, si osserva che il sistema di integrazione è stato progettato come un filtro, attraverso il meccanismo di voto. Il sistema corregge in maniera democratica i falsi negativi dei singoli algoritmi, garantendo chiarezza e sicurezza all'utente finale. Di conseguenza, l'accuratezza finale del sistema si attesta sul valore del modello più performante.

Conclusioni

Questo progetto ha dimostrato l'efficacia di un'architettura basata su modelli eterogenei per la gestione energetica domestica.

L'integrazione tra modelli di Machine Learning e Sistemi Basati sulla Conoscenza ha permesso di superare i limiti di entrambi gli approcci: se da un lato l'IA ha garantito la capacità di apprendere dai dati storici e fare predizioni, dall'altro la logica Prolog ha fornito i motivi e sicurezza indispensabile in contesti domestici.

L'integrazione ha permesso di avere un sistema unico anche nel caso in cui i modelli fornivano predizioni discordanti e, a differenza di modelli AI basati solo sulla statistica, il KBS ha dimostrato di sapere distinguere un carico alto in Fascia F1, chiedendo all'utente di diminuire il carico, e un carico alto in Fascia F3, che attiva la regola della sicurezza tecnica.

Infine, il sistema produce consigli leggibili e spiegabili, per esempio consigliare lo spegnimento dell'elettrodomestico con priorità inferiore acceso, aumentando la trasparenza e facilità di lettura del sistema stesso.

Riferimenti Bibliografici

- **Artificial Intelligence: Foundations of Computational Agents** – per la parte teorica
- **Prolog Programming for Artificial Intelligence** – per la programmazione in Prolog